

Class period 7

บทที่ 5 การเตรียมข้อมูลสำหรับการประมวลผล 1
Pandas 101 part2

1

เฉลย Homework class period 6

- คำว่า sum ของข้อมูลเชิงตัวเลข และข้อมูลเชิงหมวดหมู่
- `this_data = data_covid[['sex', 'age', 'province_of_onset']]`
- `this_data`
- เลือกข้อมูลเฉพาะคอลัมน์ที่ต้องการใช้งานและเก็บไว้ในตัวแปร `this_data`
- `female = this_data[this_data['sex']=='f']`
- เลือกแถวข้อมูลที่มีคอลัมน์ `sex` เท่ากับ หญิง เก็บไว้ในตัวแปร `female`
- `female['age']`
- เลือกแถวข้อมูลในตัวแปร `female` เฉพาะคอลัมน์ `age` ก็จะได้อายุของผู้หญิงทั้งหมด

2

เฉลย Homework class period 6

- จากข้อมูลเพื่อหาอายุเฉลี่ย
- `sum = 0`
- `N = 0`
- `for a in female['age']:`
- `if a > 0:`
- `sum += a # sum = sum + a`
- `N += 1`
- `print(f'อายุเฉลี่ยของผู้หญิง {sum/N}')`
- ถ้ารวมตัวแปร `sum=0` และ `N=0` เพื่อใช้ในการหาค่าจากการบวกในการรวมแต่ละรอบจนเสร็จรอบสุดท้าย โดย `sum` จะตรงกับอายุ และ `N` จะเป็นจำนวนผู้หญิง

3

เฉลย Homework class period 6

- `sum = 0`
- `N = 0`
- ถ้ารวมตัวแปร `sum=0` และ `N=0` เพื่อใช้ในการหาค่าจากการบวกในการรวมแต่ละรอบจนเสร็จรอบสุดท้าย โดย `sum` จะตรงกับอายุ และ `N` จะเป็นจำนวนผู้หญิง
- `for a in female['age']:`
- รวมอายุของผู้หญิงที่รวมเก็บไว้ในตัวแปร `a`
- `if a > 0:`
- ที่อยู่นอกไปข้างหน้ามากกว่า 0 มีจะนำค่าอายุมารวมคำนวณค่าเฉลี่ย เพื่อหาค่า `missing` ในกรณีไม่มีอายุ

4

เฉลย Homework class period 6

- `sum += a # sum = sum + a`
- `N += 1`
- นำตัวแปร `sum` มาบวกค่าอายุของผู้หญิงที่สะสม จบรอบ 1 รอบก็จะเอาผลลัพธ์จากการบวกรอบที่ 1 แล้วมาบวกต่อไปเรื่อยๆ เพื่อหาอายุรวม
- นำตัวแปร `N` มาบวก 1 เพื่อได้จำนวนผู้หญิง
- `print(f'อายุเฉลี่ยของผู้หญิง {sum/N}')`
- นำตัวแปร `sum` และ `N` มาหารกันเพื่อหาค่าเฉลี่ย ผลลัพธ์จะได้

5

การจัดการ Missing Value

- มีทั้งหมด 3 แบบ
- 1. `is missing`
- 2. แทนที่ค่า `missing` ด้วยค่าที่เหมาะสม `mean, default, category-unknown`
- 3. ใช้ ค่าจาก `columns`อื่นๆ มารวมมาหาค่า `column` ที่หายไป (regression, deep learning, etc.)

6

is record (dropna)

- `missing = None, NA(not authorized), NaN (not a number)`
- `dropna()` เป็นคำสั่งที่ใช้ในการลบข้อมูลแถวที่ไม่มีค่าหรือไม่ใช่ข้อมูลตัวอย่างงาน
- `data_covid.shape` ผลลัพธ์จะได้ขนาดของข้อมูล `data_covid`
- `(839771, 11)`
- `data_covid.dropna().shape` ผลลัพธ์จะได้ขนาดของข้อมูล `data_covid` ที่ลบแถวข้อมูลที่มีค่าเป็น `None`
- `(599988, 11)`

7

การใช้งาน .dropna()

- สามารถเลือกแถวข้อมูลที่เป็น `None` เฉพาะในคอลัมน์ที่ต้องการใช้งาน แทนที่จะเลือกแถวข้อมูลทั้งหมด เช่น
- `this_data = data_covid[['sex', 'age', 'province_of_onset']]`
- `this_data.shape` ผลลัพธ์จะได้
- `(839771, 3)`
- `this_data.dropna().shape` ผลลัพธ์จะได้
- `(674906, 3)`
- จะเห็นว่าเมื่อเทียบกับ `data_covid.dropna().shape` ที่เป็นข้อมูลทั้งหมด (599988, 11)
- ข้อมูลที่เลือกเฉพาะคอลัมน์ที่ต้องการใช้งานจะมีจำนวนข้อมูลมากกว่า

8

การใส่ตัวแปรเพื่อรับค่า

- `this_data.dropna()`
- `print(this_data.shape) #ndndf`
- `(839771, 3)`
- `fillna` ใช้เพื่อเติมค่าที่หายไปจาก `dropna()` เพื่อข้อมูลแถวที่มีค่าเป็น `None` เนื่องจากไม่ได้ใส่ตัวแปรรับค่า เช่น
- `this_data_dn = this_data.dropna()`
- `print(this_data_dn.shape) #ndndf`
- `(674906, 3)`

9

10

11

12

13

14

15