

# Class period 6





Pandas 101

# Pandas

- Pandas เป็นหนึ่งใน **package** ที่สำคัญของ **python** ใช้สำหรับจัดการข้อมูลรูปแบบตาราง .CSV
- `import pandas as pd`

# Download ข้อมูลรายงาน COVID-19 ประจำวัน ข้อมูล ประจำประเทศไทย

- <https://data.go.th/dataset/covid-19-daily>

 ดาวน์โหลด	รายงานจำนวนผู้ติดเชื้อ COVID-19 ประจำวัน  7,123 downloads
 ดาวน์โหลด	covid-19-daily_data_dictionary  4,364 downloads

CSV = Comma Separated Values

ในการจะใส่ค่าแต่ละค่า จะใช้ **comma** ในการแยก

Meta data = Data that description data

ใช้อธิบายข้อมูล

# การนำข้อมูลเข้า

- 1. สร้าง folder ใน google drive และนำข้อมูล .csv ที่ดาวน์โหลดเข้าไปเก็บไว้ใน folder ที่สร้าง
- 2. นำเข้า package pandas และ package ของ google.colab ที่ชื่อ drive เพื่อเชื่อมต่อ google drive กับ google colab
- `import pandas as pd`
- `from google.colab import drive`  
`drive.mount('/content/drive')`
- 3. กด Connect Google Drive และเลือก Account
- 4. กด select all และกด continue

Permit this notebook to access your Google Drive files?

This notebook is requesting access to your Google Drive files. Granting access to Google Drive will permit code executed in the notebook to modify files in your Google Drive. Make sure to review notebook code prior to allowing this access.

No thanks

Connect to Google Drive

✓  
22s

```
[1] import pandas as pd
    from google.colab import drive
    drive.mount('/content/drive')
```

Mounted at /content/drive

# Import os

- นำเข้า **package os** เพื่อใช้ในการทำงานต่างๆที่เกี่ยวกับไฟล์ เช่น การชี้ไฟล์ การลบไฟล์ การสร้างโฟลเดอร์ เป็นต้น
- โดยในกรณี **google drive** จะใช้ **os** เพื่อชี้ไฟล์ ว่าไฟล์ที่ต้องการใช้งานอยู่ **path** ไหนใน **google drive** ที่เชื่อม
- **path** คือเส้นทางที่อยู่ไฟล์ จะทำงานเหมือนกับ **path** ใน **window** เช่น
- **E:\WORKSPACE\Basic Programming\confirmed-cases.csv**
- หมายความว่า ไฟล์ **confirmed-cases.csv** อยู่ใน **drive E** โฟลเดอร์ **WORKSPACE** ในโฟลเดอร์ **Basic Programming**

# การ set path

- `path = '/content/drive/My Drive/dataviz_2024_data'`
- Set '`path`' ที่ชี้ไปยังโฟลเดอร์ที่เก็บไฟล์ `.csv` ไว้ใน **google drive** และเก็บ **string** ไว้ในตัวแปร `path`
- โดย `path` หรือเส้นทางที่ชี้ไปยังโฟลเดอร์และไฟล์ต่างๆ ใน OS ของ `window`, `mac` หรือ `linux` จะใช้สัญลักษณ์ใน `path` แตกต่างกัน
- Package `os` จะช่วยให้สามารถเชื่อม `path` โดยไม่ต้องคำนึงถึงสัญลักษณ์ เพราะ `os` จะใส่สัญลักษณ์เชื่อมให้เองตาม `platform` ที่ใช้งานอยู่ เช่น
- ถ้าใช้ OS ของ `window` ก็จะเชื่อมด้วย `\`
- ถ้าใช้ OS ของ `mac` หรือ `linux` จะเชื่อมด้วย `/`

# คำสั่ง `os.path.join`

- เป็นคำสั่งที่ใช้สำหรับเชื่อม **path** เข้าด้วยกัน
- `import os`
- `covid_file_path = os.path.join(path, 'confirmed-cases.csv')`
- หมายความว่า เชื่อมตัวแปร `path` ที่ set ไว้ก่อนหน้านี้เข้ากับชื่อไฟล์ `confirmed-cases.csv` เก็บไว้ในตัวแปร `covid_file_path`
- `print(covid_file_path)`
- ผลลัพธ์จะได้เส้นทางไปยังไฟล์ที่ต้องการอยู่ในตัวแปร `covid_file_path`
- `/content/drive/My Drive/dataviz_2024_data/confirmed-cases.csv`

# load data to memory (pd.read\_csv )

- `pd.read_csv` เป็นคำสั่งที่ใช้สำหรับโหลดข้อมูล
- `data_covid = pd.read_csv(covid_file_path)`
- โหลดข้อมูลไฟล์ `confirmed-cases.csv` ตามเส้นทาง `covid_file_path`
- `data_covid` พิมพ์ชื่อตัวแปรที่เก็บข้อมูล
- ผลลัพธ์จะได้หน้าไฟล์ csv

	No.	announce_date	notification_date	sex	age	nationality	province_of_isolation	province_of_onset	district_of_onset	
0	1	1/12/2020	NaN	หญิง	61.0	China	กรุงเทพมหานคร	กรุงเทพมหานคร	NaN	คนค้า เดิน/ จา ปร
1	2	1/17/2020	NaN	หญิง	74.0	China	กรุงเทพมหานคร	กรุงเทพมหานคร	NaN	คนค้า เดิน/ จา ปร
2	3	1/22/2020	NaN	หญิง	73.0	Thailand	นครปฐม	นครปฐม	เมือง	คนค้า เดิน/ จา ปร
3	4	1/22/2020	NaN	ชาย	68.0	China	กรุงเทพมหานคร	กรุงเทพมหานคร	NaN	คนค้า เดิน/ จา ปร
4	5	1/24/2020	NaN	หญิง	66.0	China	นนทบุรี	กรุงเทพมหานคร	NaN	คนค้า เดิน/ จา ปร
...	...	...	...	...	...	...	...	...	...	
12648	12649	1/20/2021	1/19/2021	หญิง	44.0	Thailand	ชลบุรี	ชลบุรี	บางละมุง	Quara



# คำสั่ง `.head()`

- `data_covid.shape` ชื่อตัวแปรที่เก็บข้อมูลตามด้วย `.head()` ใช้เพื่อให้เห็นชื่อคอลัมน์และข้อมูลในตารางเฉพาะ 5 แถวแรก `int, default=5`
- สามารถกำหนดจำนวนคอลัมน์ที่ต้องการให้แสดงได้ เช่น
- `data_covid.head(10)` จะแสดงชื่อคอลัมน์และข้อมูลในตาราง 10 แถว

# คำสั่ง `.shape`

- `data_covid.shape` คือตัวแปรที่เก็บข้อมูลตามด้วย `.shape` ใช้ตรวจสอบขนาดของข้อมูล ผลลัพธ์จะได้
- `(839771, 11)`
- หมายความว่า มีข้อมูลทั้งหมด 839,771 แถว มีคอลัมน์ 11 คอลัมน์

# การชี้ค่าในข้อมูลตารางแบบ basic

- ใช้ชื่อคอลัมน์ในการดึงข้อมูลในคอลัมน์ที่ต้องการ
- `data_covid['province_of_onset']`

```
data_covid['province_of_onset']
```

0	กรุงเทพมหานคร
1	กรุงเทพมหานคร
2	นครปฐม
3	กรุงเทพมหานคร
4	กรุงเทพมหานคร
	...
839766	กาญจนบุรี
839767	กาญจนบุรี
839768	กาญจนบุรี
839769	กาญจนบุรี
839770	กาญจนบุรี

Name: province\_of\_onset, Length: 839771, dtype: object

# การชี้ค่าในข้อมูลตารางแบบ basic

- การใช้ชื่อคอลัมน์และลำดับแถวในการดึงข้อมูลในแถวและคอลัมน์ที่ต้องการ
- `data_covid['province_of_onset'][4]`
- ผลลัพธ์จะได้ข้อมูลแถวที่ 4 นับจาก 0 ในคอลัมน์ province\_of\_onset
- 'กรุงเทพมหานคร'

# การชี้ค่าในข้อมูลตารางแบบ `.iloc`

- โดยการมองมุมมองข้อมูลตารางในรูปแบบ **numpy array** หรือ **matrix** จะใช้ตำแหน่งเพื่อชี้ข้อมูลที่ต้องการ เช่น
- `data_covid.iloc[4, 9]`
- ผลลัพธ์จะได้ข้อมูลแถวที่ 4 คอลัมน์ที่ 9 (ในมุมมอง **matrix** คือหลักที่ **9**) นับจาก 0 คือคอลัมน์ `province_of_onset`
- 'กรุงเทพมหานคร'

# Table slicing การเลือกข้อมูลเฉพาะคอลัมน์ที่ต้องการ

- การเลือกข้อมูลเฉพาะคอลัมน์ที่ต้องการมาเก็บไว้ในตัวแปรเพื่อนำไปใช้งาน
- `smaller_table = data_covid[['announce_date', 'province_of_onset', 'risk']]`
- หมายความว่า เลือกข้อมูลคอลัมน์ชื่อ `announce_date`, `province_of_onset`, `risk` ในข้อมูลที่เก็บอยู่ในตัวแปร `data_covid` และเก็บข้อมูลเฉพาะคอลัมน์ที่เลือกไว้ในตัวแปร `smaller_table`
- ผลลัพธ์จะได้

```
[10] smaller_table = data_covid[['announce_date', 'province_of_onset', 'risk']]
      smaller_table
```

	announce_date	province_of_onset	risk
0	12/1/2020	กรุงเทพมหานคร	คนต่างชาติเดินทางมาจากต่างประเทศ
1	17/1/2020	กรุงเทพมหานคร	คนต่างชาติเดินทางมาจากต่างประเทศ
2	22/1/2020	นครปฐม	คนต่างชาติเดินทางมาจากต่างประเทศ
3	22/1/2020	กรุงเทพมหานคร	คนต่างชาติเดินทางมาจากต่างประเทศ
4	24/1/2020	กรุงเทพมหานคร	คนต่างชาติเดินทางมาจากต่างประเทศ
...	...	...	...
839766	12/8/2021	กาญจนบุรี	กักกักสถาน/เรือนจำ
839767	12/8/2021	กาญจนบุรี	กักกักสถาน/เรือนจำ
839768	12/8/2021	กาญจนบุรี	กักกักสถาน/เรือนจำ
839769	12/8/2021	กาญจนบุรี	กักกักสถาน/เรือนจำ
839770	12/8/2021	กาญจนบุรี	กักกักสถาน/เรือนจำ

839771 rows x 3 columns

# Table slicing การเลือกข้อมูลเฉพาะแถวที่ต้องการแบบง่าย

- การเลือกข้อมูลเฉพาะแถวที่ต้องการแบบง่าย คือการมองมุมมองข้อมูลตารางในรูปแบบ **array** แต่การนำไปใช้งาน ใช้งานอะไรไม่ค่อยได้
- `data_covid.iloc[1:5, :]`
- หมายความว่า
- `1:5` คือเลือกข้อมูลที่อยู่ในแถวที่ 1 ไปจนถึงแถวที่ 4
- `, :` คือเลือกทุกคอลัมน์ ดังนั้น
- `data_covid.iloc[1:5, :]` คือเลือกข้อมูลในตัวแปร `data_covid` ที่อยู่ในแถวที่ 1 ไปจนถึงแถวที่ 4 และเลือกทุกคอลัมน์

# Table slicing การเลือกข้อมูลเฉพาะแถวที่ต้องการแบบ advanced

- การเลือกข้อมูลเฉพาะแถวที่ต้องการแบบ **advanced** คือการใช้ **logic query** ในการเลือกข้อมูล
- `data_covid[data_covid['province_of_onset'] == 'ขอนแก่น']`
- หมายความว่า เลือกข้อมูลที่อยู่ในตัวแปร `data_covid` โดยกำหนดชื่อคอลัมน์ที่ต้องการคือ `province_of_onset` และต้องการข้อมูลทุกแถวที่มีข้อมูลในคอลัมน์ `province_of_onset` เป็นจังหวัดขอนแก่น



# วิธีการเลือกข้อมูลเฉพาะแถวที่ต้องการแบบ advanced

- การทำงานของการเลือกข้อมูลเฉพาะแถวที่ต้องการแบบ advanced
- คือ การใส่แถวที่ต้องการ และใส่ **list True/False** ที่มีขนาดเท่ากับจำนวนแถว เพื่อเปรียบเทียบข้อมูลในแถวนั้นๆ ด้วยเงื่อนไข **logical expression (True/False)** เช่น
- สร้างตารางใช้สำหรับยกตัวอย่าง
- ```
eight_rows_covid = data_covid.iloc[:8, :]  
eight_rows_covid
```
- หมายความว่า เลือกข้อมูลในตัวแปร data\_covid แถวที่ 0 ถึงแถวที่ 7 ทุกคอลัมน์เก็บไว้ในตัวแปร eight\_rows\_covid

# การทำงานของเลือกข้อมูลเฉพาะแถวที่ต้องการแบบ advanced

- ใส่แถวที่ต้องการด้วยการกำหนดค่า `True` (แถวที่ต้องการ) / `False` (แถวที่ไม่ต้องการ)
- `eight_rows_covid[[True, True, False, True, True, True, True, False]]`
- ผลลัพธ์จะได้ข้อมูลตารางตามค่า `True/False` ที่เลือกใน `list` คือแถวที่ `0, 1, 3, 4, 5, 6`
- เช่นเดียวกันกับการสร้าง `list` ของ `logical expression` แต่แทนที่จะเลือกเองโดยการใส่ `list True/False` ให้กำหนดเงื่อนไขและข้อมูลที่ต้องการ เพื่อเปรียบเทียบและเลือกข้อมูลที่ตรงตามเงื่อนไข โดยถ้าตรงตามเงื่อนไขคือ `True` ไม่ตรงตามเงื่อนไขคือ `False`

# การสร้าง list ของ logical expression

- `eight_rows_covid['province_of_onset'] == 'กรุงเทพมหานคร'`
- ผลลัพธ์จะได้
- 0        True
- 1        True
- 2        False
- 3        True
- 4        True
- 5        True
- 6        True
- 7        False
- Name: province\_of\_onset, dtype: bool

# นำ list ของ logical expression ที่สร้างมาใช้งาน

- ซึ่งเมื่อนำมาใช้งานเลือกข้อมูลเฉพาะแถวที่ต้องการแบบ **advanced** คือการใช้ **logic query** ในการเลือกข้อมูล นั้นเอง
- `eight_rows_covid[eight_rows_covid['province_of_onset'] == 'กรุงเทพมหานคร']`
- ผลลัพธ์จะได้ข้อมูลทุกแถวที่มีข้อมูลในคอลัมน์ **province\_of\_onset** เป็น กรุงเทพมหานคร คือแถวที่ 0, 1, 3, 4, 5, 6

# Homework class period 6

- (ให้ใช้เฉพาะที่อาจารย์สอนไปแล้วในวิชานี้)
- คำนวณ อายุเฉลี่ย ของผู้หญิง และผู้ชาย ของข้อมูลทั้งหมด
- คำนวณ อายุเฉลี่ย ของผู้หญิง และผู้ชาย ของผู้ป่วยในจังหวัดขอนแก่น
- หาจำนวนผู้ป่วยที่เป็นคน "คนต่างชาติเดินทางมาจากต่างประเทศ"