Class period 7

Pandas 101 part2

เฉลย Homework class period 6

- คำนวณ อายุเฉลี่ย ของผู้หญิง และผู้ชาย ของข้อมูลทั้งหมด
- `this_data = data_covid[['sex','age','province_of_onset']]`
- `this_data`
- เลือกข้อมูลเฉพาะคอลัมน์ที่ต้องการใช้งานและเก็บไว้ในตัวแปร `this data`
- `female = this_data[this_data['sex']=='หญิง']`
- เลือกแถวข้อมูลที่ข้อมูลในคอลัมน์ sex เท่ากับ หญิง เก็บไว้ในต้วแปร female
- `female['age']`
- เลือกแสดงข้อมูลในตัวแปร `female` เฉพาะคอลัมน์ `age` ก็จะได้ข้อมูลอายุของเพศหญิงทั้งหมด

เฉลย Homework class period 6

- จากนั้นวนลูปเพื่อหาอายุเฉลี่ย

```
sum = 0
N = 0
for a in female['age’]:
    if a > 0:
        sum += a # sum = sum + a
        N += 1
print(f'อายุเฉลี่ย ของ ผู้ป่วยหญิง {sum/N}’)
```

- กำหนดตัวแปร sum=0 และ N=0 เพื่อใช้ในการเก็บค่าจากการบวกในการวนลูปแต่ละรอบจนถึงรอบสุดท้าย โดย sum จะใช้เก็บค่าอายุ และ N ใช้เก็บค่าจำนวนผู้หญิง

เฉลย Homework class period 6

- `sum = 0`
- `N = 0`
- กำหนดตัวแปร sum=0 และ N=0 เพื่อใช้ในการเก็บค่าจากการบวกในการวนลูปแต่ละรอบจนถึงรอบสุดท้าย โดย sum จะใช้เก็บค่าอายุ และ N ใช้เก็บค่าจำนวนผู้หญิง
- `for a in female['age']:`
- วนลูปอ่านค่าอายุของผู้หญิงที่ละคนเก็บไว้ในตัวแปร a
- `if a > 0:`
- ตั้งเงื่อนไขในค่าอายุมากกว่า 0 ถึงจะนำค่าอายุมาบวกคำนวณหาค่าเฉลี่ย เพื่อหลีกเลี่ยงค่า missing (บางคนไม่มีข้อมูลอายุ)

เฉลย Homework class period 6

- `sum += a # sum = sum + a`
- `N += 1`
- นำตัวแปร `sum` มาบวกค่าอายุของผู้หญิงทีละคน จบลูป `1` รอบก็จะเอาผลลัพธ์จากการบวกรอบที่แล้วมาบวกต่อไปเรื่อยๆ เพื่อหาค่าอายุรวม
- นำตัวแปร `N` มาบวก `1` เพื่อใช้นับจำนวนผู้หญิง
- `print(f'อายุเฉลี่ย ของ ผู้ป่วยหญิง {sum/N}')`
- นำตัวแปร sum และ N มาหารกันเพื่อหาค่าเฉลี่ย ผลลัพธ์จะได้

การจัดการ Missing Value

- มีทั้งหมด 3 แบบ
- 1. ลบ record ที่เป็น missing
- 2. แทนที่ ค่า missing ด้วยค่าที่เหมาะสม mean, default, category-unknown
- 3. ใช้ ค่าจาก columns อื่นๆ ช่วยประมาณค่า ค่าใน column ที่หายไป (regression, deep learning, etc.)

ลบ record (dropna)

- missing = None, NA(not autorized), NaN (not a number)
- .dropna() เป็นคำสั่งที่ใช้ในการลบข้อมูลแถวที่ไม่มีค่าหรือไม่มีข้อมูล ตัวอย่างเช่น
- `data_covid.shape` ผลลัพธ์จะได้ขนาดของข้อมูล `data_covid`
- `(839771, 11)`
- `data_covid.dropna().shape` ผลลัพธ์จะได้ขนาดของข้อมูล `data_covid` ที่ลบแถวข้อมูลที่มีค่าเป็น `None`
- `(599988, 11)`

การใช้งาน .dropna()

- สามารถเลือกลบข้อมูลที่เป็น None เฉพาะในคอลัมน์ที่ต้องการใช้งาน แทนที่จะเลือกลบจากข้อมูลทั้งหมด เช่น
- `this_data = data_covid[['sex','age','province_of_onset’]]`
- `this_data.shape` ผลลัพธ์จะได้
- `(839771, 3)`
- `this_data.dropna().shape` ผลลัพธ์จะได้
- `(674906, 3)`
- จะเห็นว่าเมื่อเทียบกับ `data_covid.dropna().shape` ที่เป็นข้อมูลทั้งหมด `(599988, 11)`
- ข้อมูลที่เลือกเฉพาะคอลัมน์ที่ต้องการใช้งานจะมีจำนวนข้อมูลมากกว่า

การใส่ตัวแปรเพื่อรับค่า

- `this_data.dropna()`
- `print(this_data.shape)` ผลลัพธ์จะได้
- `(839771, 3)`
- ซึ่งไม่ใช่ผลลัพธ์ที่ได้จากการใช้ `.dropna()` เพื่อลบข้อมูลแถวที่มีค่าเป็น `None` เนื่องจากไม่ได้มีตัวแปรเข้ารับค่า เช่น
- `This_data_dn = this_data.dropna()`
- `print(This_data_dn.shape` ผลลัพธ์จะได้
- `(674906, 3)`

Parameter: inplace ของ .dropna()

- `inplace` จะเป็นการอัพเดทค่าในตารางเลย โดยที่ไม่จำเป็นต้องมีตัวแปรที่มารับค่า เช่น
- `this_data.dropna(inplace=True)`
- `print(this_data.shape)`
- `(674906, 3)`

pandas.DataFrame.dropna

DataFrame.dropna(*, *axis*=0, *how*=_NoDefault.no_default, *thresh*=_NoDefault.no_default, *subset*=None, *inplace*=False, *ignore_index*=False) [source]

Remove missing values.

See the User Guide for more on which values are considered missing, and how to work with missing data.

Parameters:

axis : *{0 or 'index', 1 or 'columns'}, default 0*

Determine if rows or columns which contain missing values are removed.

- 0, or 'index' : Drop rows which contain missing values.
- 1, or 'columns' : Drop columns which contain missing value.

Only a single axis is allowed.

how : *{'any', 'all'}, default 'any'*

Determine if row or column is removed from DataFrame, when we have at least one NA or all NA.

- 'any' : If any NA values are present, drop that row or column.
- 'all' : If all values are NA, drop that row or column.

thresh : *int, optional*

Require that many non-NA values. Cannot be combined with how.

subset : *column label or sequence of labels, optional*

Labels along other axis to consider, e.g. if you are dropping rows these would be a list of columns to include.

inplace : *bool, default False*

Whether to modify the DataFrame rather than creating a new one.

ignore_index : *bool, default* `False`

If `True`, the resulting axis will be labeled 0, 1, …, n - 1.

Parameter: subset ของ .dropna()

- subset จะเป็นการเลือกเฉพาะคอลัมน์ที่ต้องการลบแถวข้อมูลที่เป็น None เฉพาะคอลัมน์ที่เลือก เช่น
- this_data = data_covid[['sex','age','province_of_onset’]]
- this_data.shape ขนาดของข้อมูลตาราง
- (839771, 3)
- this_data.dropna().shape ขนาดของข้อมูลตารางที่มีการลบข้อมูลแถวที่เป็น None แบบปกติ
- (674906, 3)
- this_data.dropna(subset=['age']).shape
- ขนาดของข้อมูลตารางที่มีการกำหนด subset ลบข้อมูลแถวที่เป็น None เฉพาะ subset ที่กำหนด
- (763606, 3)

แทน missing ด้วยค่าที่เหมาะสม (fillna)

- `.fillna()` เป็นคำสั่งที่ใช้ในการแทนที่ค่า missing หรือค่า None ด้วยค่าที่กำหนด เช่น
- `this_data = data_covid[['sex','age','province_of_onset']]`
- `this_data_updated = this_data.fillna(value={'sex':'ไม่รู้','age':-1, 'province_of_onset':'ไม่รู้'})`
- หมายความว่า ให้แทนที่ข้อมูลที่เป็น None
- ในคอลัมน์ sex แทนด้วย ‘ไม่รู้’
- ในคอลัมน์ age แทนด้วย -1
- และในคอลัมน์ province_of_onset ให้แทนที่ค่า None ด้วย ‘ไม่รู้’
- ผลลัพธ์จะได้ข้อมูลตาราง `this_data_updated` ที่ไม่มีค่า None

แทน missing ด้วยค่าที่เหมาะสม (fillna)

- สามารถตรวจสอบว่าค่า None ถูกแทนที่ด้วยค่าที่กำหนดไว้แล้วรึยังด้วย
- `this_data_updated[this_data_updated['sex']=='ไม่รู้']`
- ผลลัพธ์จะเห็นว่ามีข้อมูลในคอลัมน์ sex ที่ถูกแทนที่ด้วย ‘ไม่รู้’

```
this_data_updated[this_data_updated['sex']=='ไม่รู้']
```

	sex	age	province_of_onset
4397	ไม่รู้	-1	สมุทรสาคร
4398	ไม่รู้	-1	สมุทรสาคร
4399	ไม่รู้	-1	สมุทรสาคร
4400	ไม่รู้	-1	สมุทรสาคร
4401	ไม่รู้	-1	สมุทรสาคร
...	...	...	...
838332	ไม่รู้	3.0	กรุงเทพมหานคร
839174	ไม่รู้	47.0	กรุงเทพมหานคร
839304	ไม่รู้	-1	ไม่รู้
839396	ไม่รู้	-1	นครราชสีมา
839397	ไม่รู้	-1	นครราชสีมา

54895 rows × 3 columns

การใช้ logical expression จากข้อมูลตารางอื่น

- `data_covid[this_data_updated['province_of_onset']=='ไม่รู้']`

- จะเห็นได้ว่าในส่วนที่กำหนดเงื่อนไขของ logical expression มาจากตัวแปร this_data_updated ซึ่งนำมาใช้ในข้อมูลตารางของตัวแปร data_covid
- สาเหตุที่สามารถนำมาใช้ด้วยกันได้และผลออกมาถูกต้อง 2 ตัวแปรที่เป็นข้อมูลตารางต้องมีจำนวนแถวเท่ากันและในแต่ละแถวมีข้อมูลเหมือนกันตำแหน่งเดียวกัน
- ถ้าหาก 2 ตัวแปรมีจำนวนแถวเท่ากันแต่ในแต่ละแถวมีข้อมูลไม่เหมือนกันก็สามารถใช้งานได้ แต่ผลลัพธ์ที่ได้อาจจะไม่ถูกต้องเพราะไม่ใช้ข้อมูลเดียวกัน

การวนลูป record ในตาราง (.iterrows)

- .iterrows() เป็นคำสั่งที่ช่วยในสามารถวนลูปอ่านข้อมูลในตาราง
- this_data = data_covid[['sex','age','province_of_onset’]]
- for each_row in this_data.**iterrows()**:
- if (each_row[1]['age'] == 20) and (each_row[1]['province_of_onset'] == 'ขอนแก่น’):
- print(each_row)
- หมายความว่า
- ให้วนลูปอ่านค่าในข้อมูลตารางตัวแปร this_data ทีละแถวและเก็บในตัวแปร each_row
- ส่วนทำงานภายในลูปกำหนดเงื่อนไขโดยกำหนดให้เลือก print ข้อมูลเฉพาะแถวที่มีข้อมูลในตาราง age=20 และ province_of_onset=ขอนแก่น