

Class period 8

Pandas 101 part3

Quiz สุ่มชื่อ (5 นาที)

- ให้อ่านค่าข้อมูลในตารางโดยใช้ `.iloc` ที่แบบ `numpy array` หรือ `matrix` ให้ผลลัพธ์ออกมาเหมือนใช้ `.iterrows()`
- `this_data = data_covid[['sex', 'age', 'province_of_onset']]`
- `for each_row in this_data.iterrows():`
- `if (each_row[1]['age'] == 20) and`
`(each_row[1]['province_of_onset'] == 'ขอนแก่น'):`
- `print(each_row)`

การวนลูป มองตารางแพนด้าส์(pandas dataframe) เป็น numpy array หรือ matrix (.iloc)

- `this_data = data_covid[['sex', 'age', 'province_of_onset']]`
- `for each_row in range(this_data.shape[0]):`
- `if (this_data.iloc[each_row,1] == 20) and`
`(this_data.iloc[each_row,2] == 'ขอนแก่น'):`
- `print(each_row)`
- `print(this_data.iloc[each_row,:])`

การวนลูป

- `for each_row in range(this_data.shape[0]) :`
- วนลูปอ่านลำดับแถวในตารางทีละแถวเก็บไว้ในตัวแปร `each_row` โดยจำนวนแถวทั้งหมดในตารางสามารถหาได้จาก
 - `this_data.shape`
 - `(839771, 3)`
 - `this_data.shape[0]`
 - `839771`
- `range(this_data.shape[0])` คือ สร้าง `list` ตัวเลขตามจำนวนแถวทั้งหมดเพื่อใช้วนลูปเข้าทีละแถว
- `[0, 1, 2, 3, ..., 839771]`

การใช้ .iloc ในการชี้ข้อมูลในตาราง

- `if (this_data.iloc[each_row, 1] == 20) and (this_data.iloc[each_row, 2] == 'ขอนแก่น'):`
- สร้างเงื่อนไขสำหรับเลือกเฉพาะข้อมูลที่ต้องการคือ **age=20** และ **province_of_onset=ขอนแก่น** โดยชี้ด้วย **.iloc** ตามด้วย **each_row** คือลำดับแถวจากกลุ่มและลำดับคอลัมน์(หลัก)ของข้อมูลที่ต้องการ ดังนั้น
- `this_data.iloc[each_row, 1] == 20` คือ ชี้ข้อมูลแต่ละแถวในคอลัมน์ age (หลักที่ 1 นับจาก 0) ตรวจสอบว่าเท่ากับ 20 ในตัวแปร `this_data` ที่เก็บตารางข้อมูล
- `this_data.iloc[each_row, 2] == 'ขอนแก่น'`: คือ ชี้ข้อมูลแต่ละแถวในคอลัมน์ `province_of_onset` (หลักที่ 2) ตรวจสอบว่าเท่ากับ 'ขอนแก่น' ในตัวแปร `this_data` ที่เก็บตารางข้อมูล

print แสดงข้อมูล

- `print(each_row)`
- `print(this_data.iloc[each_row,:])`
- เมื่อผ่านเงื่อนไข ให้
- `print each_row` คือ ตัวเลขลำดับแถว และ
- `print this_data.iloc[each_row,:])` คือ ข้อมูลในแถวนั้นๆ ทุกคอลัมน์

Quiz ในห้อง (15 นาที)

- ตัดตารางออกมาเฉพาะปี 2021 `announce_date` ในปี 2021
- Hint
- วนลูปหา `index` ของปี 2021
- ตัดตารางมาเฉพาะ ปี 2021

เฉลย

- `TF=list()`
- `for each_row in data_covid.iterrows():`
- `if each_row[1]['announce_date'].split('/')[2] == '2021':`
- `TF.append(True)`
- `else:`
- `TF.append(False)`
- `data_covid[TF].head()`

เตรียม list วาง วนลูปและสร้างเงื่อนไข

- `TF=list()`
- สร้าง **list** วางเก็บไว้ในตัวแปร **TF** เพื่อเตรียมรับผลลัพธ์ **True False** ที่ได้จากการวนลูป
- `for each_row in data_covid.iterrows():`
- วนลูปอ่านค่าในข้อมูลตารางตัวแปร `data_covid` ที่ละแถวและเก็บในตัวแปร `each_row`
- `if each_row[1]['announce_date'].split('/')[2] == '2021':`
- สร้างเงื่อนไขเพื่อหาข้อมูลที่มีค่าในคอลัมน์ `announce_date` เท่ากับ 2021 โดยการใช้ `.split('/')[2]` เพื่อแยกข้อความให้เหลือเฉพาะปีสำหรับการเปรียบเทียบ
- ข้อมูลวันเดือนปีในคอลัมน์ `announce_date` รูปแบบเป็น 3/11/2021 คือ วัน/เดือน/ปี
- ดังนั้นแยกด้วยสัญลักษณ์ / ปีจะอยู่ตำแหน่งที่ 2 นับจาก 0

เขียน True False เข้าไปใน List

- `if each_row[1]['announce_date'].split('/')[2] == '2021':`
- `TF.append(True)`
- `else:`
- `TF.append(False)`
- ถ้าผ่านเงื่อนไขให้เขียน **True** เข้าไปใน **list** ที่เตรียมไว้ ถ้าไม่ผ่านให้เขียน **False**
- หมายความว่า ถ้าข้อมูลปีในคอลัมน์ **announce_date** เท่ากับ **2021** ให้เขียน **True** เข้าไปใน **list** ถ้าไม่ ให้เขียน **False**
- ผลลัพธ์จะได้ **list True False** ตามจำนวนแถวในข้อมูลตาราง `data_covid` ที่เลือก **True** เฉพาะปี 2021

ผลลัพธ์

- `data_covid[TF].head()`
- ให้เลือกข้อมูลตาม **list true false** ที่ได้จากการวนลูปเลือกเฉพาะปี 2021
- ผลลัพธ์จะได้ตารางข้อมูลที่มีแต่ข้อมูลในคอลัมน์ **announce_date** เท่ากับ 2021

```
data_covid[TF].head()
```

	No.	announce_date	Notified date	sex	age	Unit	nationality	province_of_isolation	ri
124	125	6/3/2021	5/3/2021	หญิง	55.0	ปี	Thailand	ปทุมธานี	Clus ตลาด พั...
6885	6886	1/1/2021	31/12/2020	หญิง	40.0	ปี	Thailand	กรุงเทพมหานคร	Clus สมุทรสา...
6886	6887	1/1/2021	31/12/2020	หญิง	21.0	ปี	Thailand	ปทุมธานี	Clus ระย...
6887	6888	1/1/2021	31/12/2020	หญิง	20.0	ปี	Thailand	นครปฐม	สธ บ้าน...
6888	6889	1/1/2021	31/12/2020	หญิง	47.0	ปี	Thailand	สมุทรสาคร	Clus สมุทรสา...

Function ตัวช่วยใน pandas

- `.describe()` คำนวณค่าทางสถิติของข้อมูลที่เป็นตัวเลข
- `.mean()` คำนวณค่าเฉลี่ยของข้อมูลโดยไม่สนใจ **missing**
- `.isnull()` ตรวจสอบข้อมูลที่ **missing (none)**

.describe()

- ใช้สำหรับคำนวณค่าทางสถิติของข้อมูลที่เป็นตัวเลข
- ไม่นำข้อมูลที่เป็น **missing** หรือ **none** มาคำนวณ
- (ลบข้อมูลแถวที่มีค่าเป็น **none** ให้อัตโนมัติ)

```
data_covid.describe()
```

	No.	age
count	839771.000000	763605.000000
mean	419886.000000	35.700109
std	242421.150791	16.597799
min	1.000000	0.750000
25%	209943.500000	24.000000
50%	419886.000000	34.000000
75%	629828.500000	46.000000
max	839771.000000	440.000000

.mean()

- ใช้สำหรับช่วยคำนวณค่าเฉลี่ยของข้อมูลโดยไม่สนใจ **missing** (ลบข้อมูลแถวที่มีค่าเป็น **none** ให้อัตโนมัติ)
- `data_covid[data_covid['sex'] == 'ชาย']['age'].mean()`
- ผลลัพธ์จะได้
- `34.96292702130938`

.isnull()

- ใช้ตรวจสอบค่า **missing** ในข้อมูลตาราง
- ถ้าเป็น **True** คือ **missing** (ค่าว่าง)
- ถ้าเป็น **False** คือไม่ใช่ค่าว่าง

data_covid.isnull()										
	No.	announce_date	Notified date	sex	age	Unit	nationality	province_of_isolation		
0	False	False	True	False	False	False	False	False	False	
1	False	False	True	False	False	False	False	False	False	
2	False	False	True	False	False	False	False	False	False	
3	False	False	True	False	False	False	False	False	False	
4	False	False	True	False	False	False	False	False	False	
...
839766	False	False	False	False	False	False	True	False	False	
839767	False	False	False	False	False	False	False	False	False	
839768	False	False	False	False	False	False	False	False	False	
839769	False	False	False	False	False	False	False	False	False	
839770	False	False	False	False	False	False	False	False	False	
839771 rows x 11 columns										