Class period 20

Histogram and render chart

ตัวอย่างข้อมูล wongnai.com

- `import matplotlib matplotlib.rcParams['figure.figsize']=[15,15]`
- `output = plt.hist(list(data['number_of_result']),10,facecolor = 'red' ,alpha = 0.75)`

- สร้างกราฟ Histogram โดยใช้ข้อมูลคอลัมน์ 'number_of_result' ใน ข้อมูล wongnai.com โดยกำหนดช่วงของข้อมูลหรือจำนวนแท่งเป็น 10 กำหนดสีเป็นสีแดง กำหนดค่าความโปรงแสงเป็น 75%

ผลลัพธ์จะได้กราฟ Histogram ที่แกน x ที่เรียงข้อมูลผิด

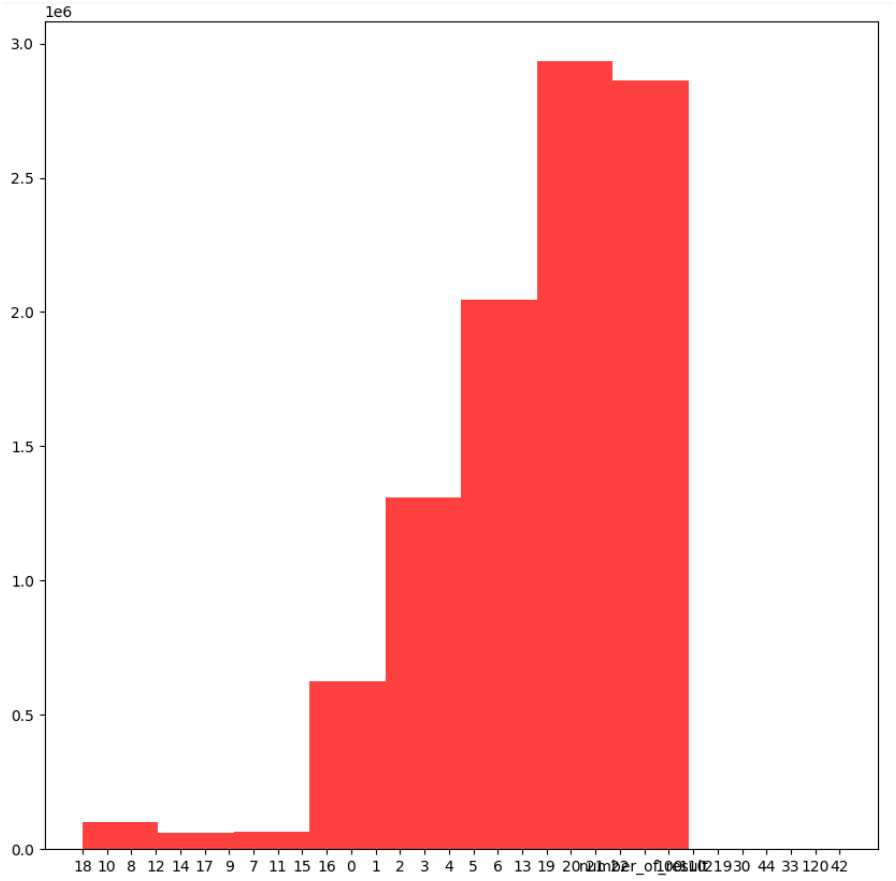

แก้ไข แกน x ที่เรียงข้อมูลผิด

- 1. ตรวจสอบ data type ของ ตัวแปร ด้วย
- `data.dtypes`
- 2. เรียกดูและตรวจสอบ data type ของตัวแปรในคอลัมน์ทีละตัวด้วย
- `type(data['number_of_result'][0])`
- `type(data['number_of_result'][0]) == int`
- 3. ลองบังคับเปลี่ยน type ข้อมูลเป็น int
- `new_type = data['number_of_result'].astype('int32')`

ลบ record

- จากการการบังคับเปลี่ยน type ข้อมูลเป็น int จะเจอ Error ว่ามีค่าในคอลัมน์ 'number_of_result' ที่เป็น number_of_result ทำให้ไม่สามารถเปลี่ยน type ข้อมูลเป็น int ได้ ดังนั้นทำการใช้ drop ลบข้อมูลแถวที่มีค่าเป็น number_of_result ทิ้ง

- 1. ตรวจสอบว่า record ใดบ้างที่มีค่าเป็น number_of_result
- `data[data['number_of_result']=='number_of_result']`
- ผลลัพธ์จะได้ record ที่ 1000016

- 2. ลบ record ที่มีค่าเป็น number_of_result
- `data = data.drop(1000016)`

บังคับเปลี่ยน type ข้อมูลเป็น int

- บังคับเปลี่ยน type ข้อมูลเป็น int หลังจากลบข้อมูล record ที่ 1000016 แล้ว และเก็บข้อมูลที่แปลงแล้วไว้ในตัวแปร new_type
- `new_type = data['number_of_result'].astype('int32’)`

- สร้างกราฟ Histogram ด้วยข้อมูลในตัวแปร new_type
- `output = plt.hist(new_type,100,facecolor = 'red' ,alpha = 0.75)`

ผลลัพธ์จะได้กราฟ Histogram ที่มี outlier

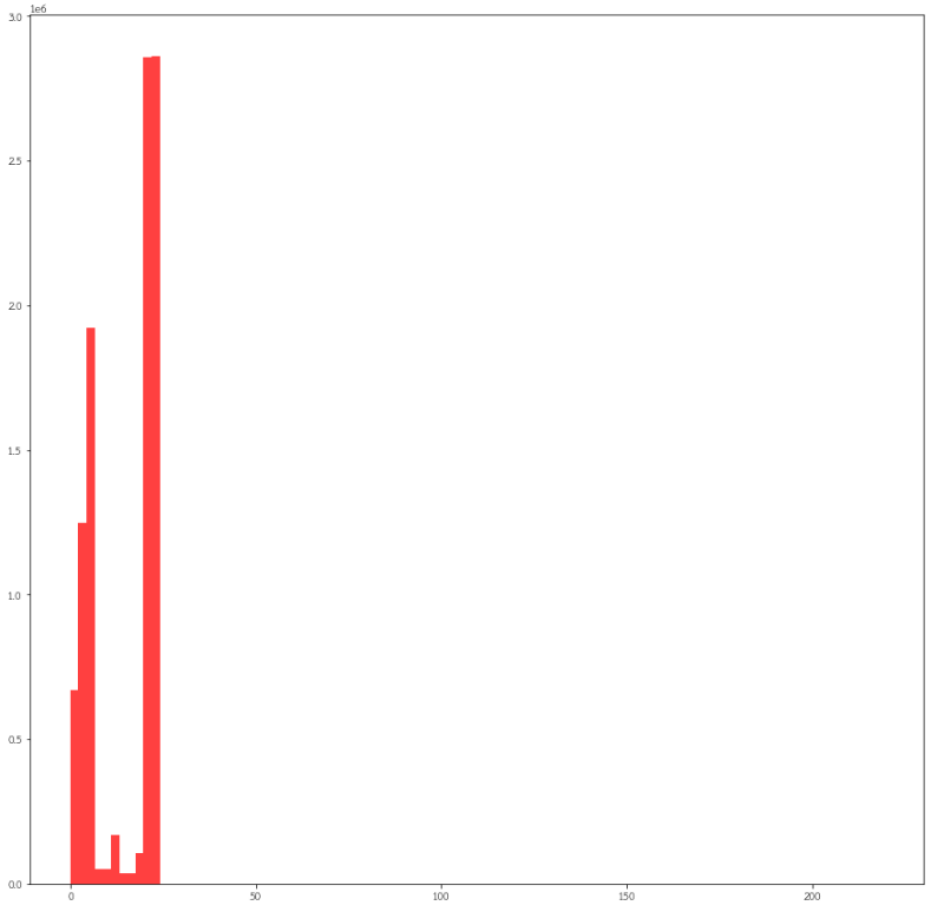

ลบ outlier

- ลบ outlier โดยการใส่เงื่อนไขให้เก็บเฉพาะข้อมูลที่มีค่าต่ำกว่า 25 ลงไป ไว้ในตัวแปรใหม่
- `new_type_nooutlier = new_type[new_type < 25]`

- ตรวจสอบว่าข้อมูลที่เป็น outlier มีกี่ตัว
- `new_type.shape[0] - new_type_nooutlier.shape[0]`
- ผลลัพธ์จะได้ว่ามี outlier ทั้งหมด 14 ตัว

```
new_type.shape[0] - new_type_nooutlier.shape[0]
```

```
14
```

สร้างกราฟ Histogram ด้วยข้อมูลในตัวแปร new_type_nooutlier

- `matplotlib.rcParams['figure.figsize']=[8,8]`
- `output = plt.hist(new_type_nooutlier,10,facecolor = 'red' ,alpha = 0.75)`

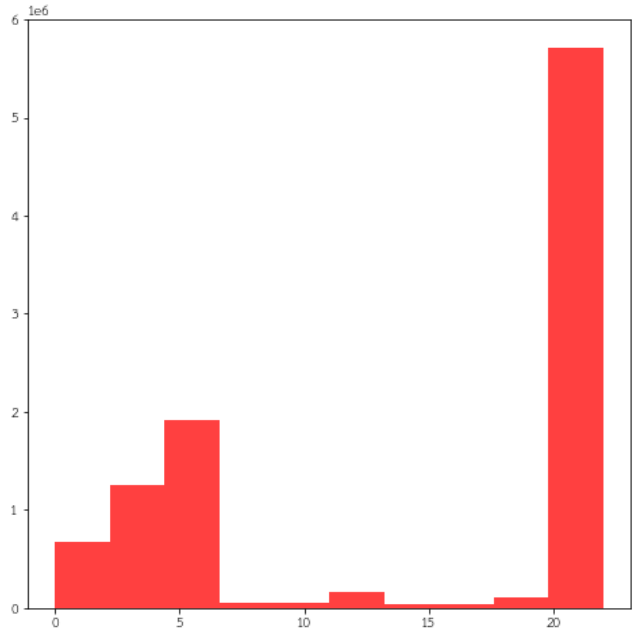

Quiz

- เปรียบเทียบความถี่ของแท่งที่มีค่ามากที่สุด กับ แท่งอื่นๆรวมกัน

เฉลย

- output ดูว่าค่าในแต่ละแท่งกราฟเป็นเท่าไหร่ จากผลลัพธ์ที่ได้แท่งสุดท้ายคือ ค่าความถี่ที่มีค่ามากที่สุด 5717238

```
(array([ 670293., 1247269., 1921441.,   51703.,   50609.,  167502.,
          36883.,   35914.,  105490., 5717238.]),
 array([ 0. ,  2.2,  4.4,  6.6,  8.8, 11. , 13.2, 15.4, 17.6, 19.8, 22. ]),
 <a list of 10 Patch objects>)
```

- output[0] เลือกมาเฉพาะ array ตัวที่ 0 ของ output คือค่าความถี่ของแท่งกราฟ

```
array([ 670293., 1247269., 1921441.,   51703.,   50609.,  167502.,
          36883.,   35914.,  105490., 5717238.])
```

เฉลยต่อ

- `output[0][-1]` ค่าความถี่ของแท่งที่มีค่ามากที่สุด
- `5717238.0`

- `sum(output[0][:-1])` ค่าความถี่ของแท่งอื่นๆรวมกัน
- `4287104.0`

Tree map

- การนำปริมาณข้อมูลที่ต้องการมาเปรียบเทียบกันในรูปแบบพื้นที่ ต่างจากกราฟแท่งที่จะเปรียบเทียบความสูง
- สามารถใช้งานการสร้าง Tree map ด้วย packet squarify โดยจะต้อง install packet ก่อนใช้งานด้วยคำสั่ง
- `!pip install squarify`
- `import squarify`
- `import numpy as np`
- `import matplotlib.pyplot as plt`

การใช้งาน squarify

- `squarify.plot('ตัวแปรข้อมูลที่ต้องการสร้าง tree map')` เช่น
- `squarify.plot(output[0])`

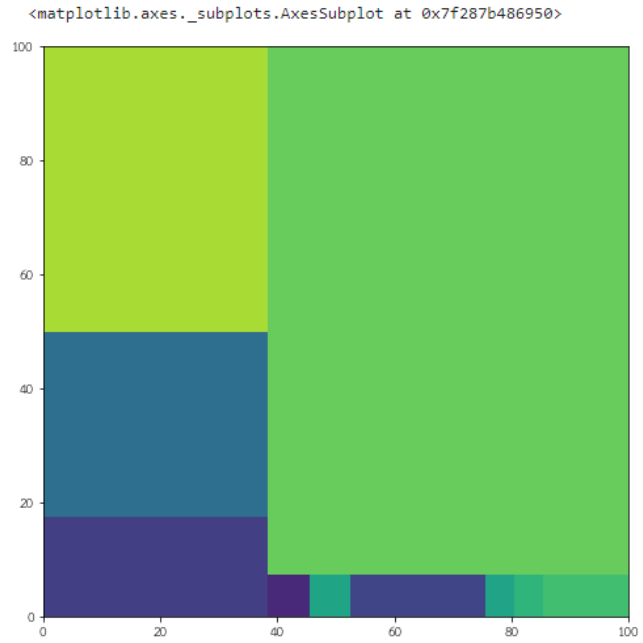

Parameter: value ของ squarify

- ใช้ Parameter: value เพื่อแสดงค่าในพื้นที่แต่ละพื้นที่ในกราฟ tree map เช่น
- `squarify.plot(output[0],value=output[0])`

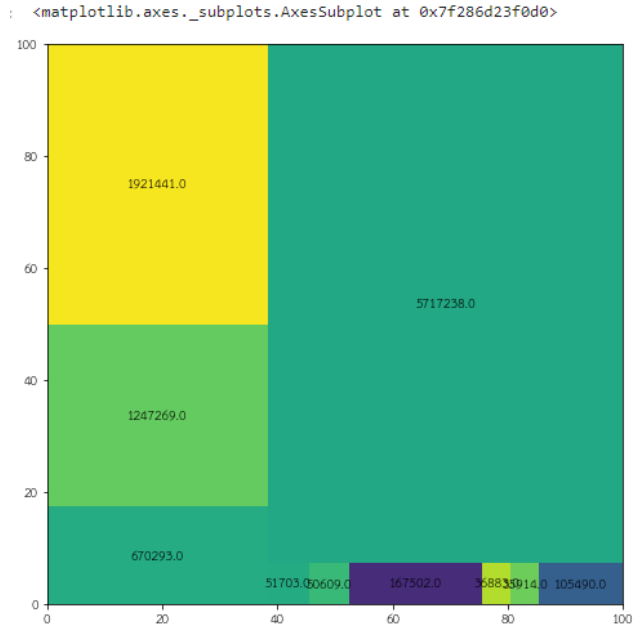

Parameter: norm_y ของ squarify

- ใช้ Parameter: norm_y ในการเปลี่ยนรูปแบบของการจัดเรียงพื้นที่กราฟ tree map ตามที่ต้องการเพื่อให้ดูกราฟง่ายขึ้น เช่น
- `squarify.plot(output[0],value=output[0],norm_y=60)`

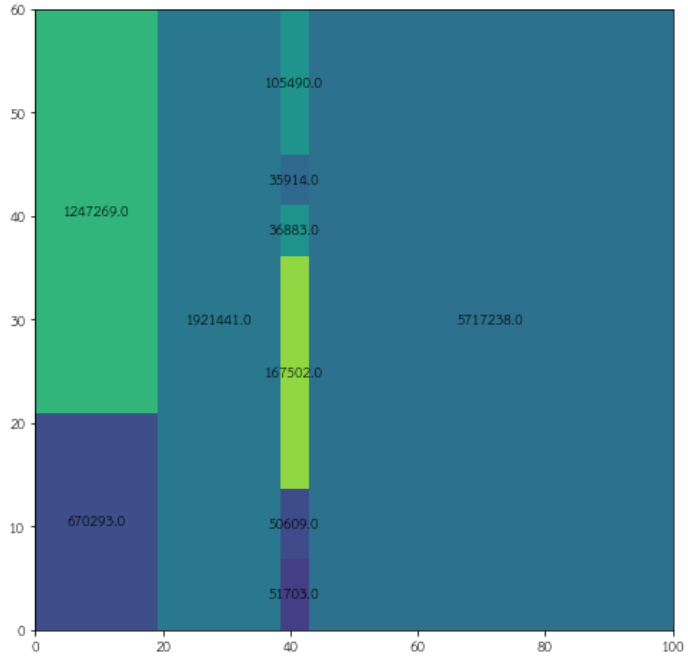

Radar Chart

- เป็นกราฟที่สามารถเปรียบเทียบข้อมูลในรูปแบบมุมแต่ละมุมโดยจะคำนวณค่า mean ของข้อมูลมาวาดกราฟมุมแต่ละมุม